

Отчет о ходе работы над проектом по глубокому обучению

Проект посвящен сегментации сосудов сетчатки на датасете DRIVE при сильном дисбалансе классов. Основная сложность задачи состоит в том, что фон занимает большую часть изображения, а сосуды — малую долю пикселей. Особенно трудно выделять тонкие сосуды: они низкоконтрастные, занимают мало пикселей и часто теряются при обучении на стандартных функциях потерь.

Задача формулировалась как бинарная сегментация: для каждого пикселя нужно определить, относится он к сосуду или к фону. Из-за преобладания фона ассурасу может быть завышенной, поэтому основными метриками были выбраны Dice, IoU, Precision и Recall.

На первом этапе был проведен анализ данных. DRIVE содержит 40 цветных изображений глазного дна; в обучающей части доступны 20 изображений и 20 бинарных масок сосудов. Размер изображений составляет 584×565 пикселей. Для экспериментов использовался train/validation split 16/4. Также применялась FOV mask, чтобы не учитывать черную область вне сетчатки при подсчете метрик. EDA подтвердил выраженный дисбаланс: по всему изображению сосуды занимают около 8.6% пикселей, а внутри FOV — около 12.5%.

После анализа данных был построен общий пайплайн: загрузка изображений и масок, применение FOV mask, предобработка, обучение моделей и расчет метрик. В финальной версии предобработка включала green channel, CLAHE, resize до 512×512 и нормализацию. Green channel использовался потому, что на изображениях глазного дна сосуды обычно лучше видны именно в зеленом канале: в нем выше контраст между сосудами и тканью сетчатки, тогда как красный канал часто слишком светлый, а синий — более шумный. CLAHE применялся для локального усиления контраста на снимках с неравномерным освещением. После этого изображения нормализовались, чтобы привести значения пикселей к единому масштабу и сделать обучение более стабильным.

Помимо финального варианта предобработки, были проверены дополнительные подходы. Для повышения разнообразия обучающей выборки тестировались отражения, повороты, сдвиги, изменения масштаба, яркости, контраста и гаммы, а также гауссовский шум и легкое размытие. Однако на DRIVE эти аугментации не дали прироста качества: вероятно, часть преобразований искажала тонкие сосудистые структуры.

Также был протестирован метод морфологического открытия. Он состоит из эрозии и дилатации и позволяет получить сглаженную фоновую компоненту изображения. В работе использовалось ядро 15×15 пикселей; после получения фоновой компоненты она вычиталась из исходного зеленого канала. Ожидалось, что это повысит контраст

сосудов относительно фона, но на практике вместе с фоном частично подавлялись тонкие сосуды, поэтому метод не вошел в финальную конфигурацию.

Еще одним исследованным методом был Non-local Means фильтр. Он усредняет похожие участки изображения внутри заданной области поиска и теоретически должен уменьшать шум с сохранением границ. В экспериментах использовались окно шаблона 7×7 пикселей, область поиска 21×21 пикселей и коэффициент фильтрации $h = 7$. На практике фильтр сглаживал самые тонкие сосудистые ветви, поэтому также не был включен в итоговый пайплайн.

Затем был реализован baseline — U-Net с encoder ResNet34 и функцией потерь BCEWithLogitsLoss. Он использовался как точка отсчета для оценки дальнейших методов борьбы с дисбалансом. На валидации baseline показал Dice = 0.6978, IoU = 0.5358, Precision = 0.7234, Recall = 0.6739, Accuracy = 0.9212. Это показало, что стандартная модель находит часть сосудов, но для тонких и слабо выраженных сосудистых структур ее качества недостаточно.

После baseline были протестированы loss-level методы борьбы с дисбалансом: BCE, Weighted BCE, BCE + Dice, Focal Loss, Tversky Loss, Focal Tversky Loss и BCE + MCC. Эти функции по-разному меняют процесс обучения: увеличивают вес ошибок на классе сосудов, фокусируются на сложных пикселях или регулируют баланс между FP и FN. Это позволило проверить, какие функции потерь лучше помогают модели работать с малым классом сосудов.

Отдельно была изучена совместная функция потерь из статьи Yan et al. Обычная pixel-wise loss оценивает ошибку по отдельным пикселям, поэтому тонкие сосуды слабо влияют на обучение из-за малого числа пикселей. Segment-level часть учитывает сосуды как связные структуры: для этого строились дополнительные карты на основе скелетизации маски, выделения сосудистых сегментов и оценки их характеристик. Этот подход сложнее стандартных loss-функций, но лучше отражает проблему сохранения сосудистой сети.

Кроме функций потерь, была протестирована архитектура SA-UNetv2 — облегченная U-Net-подобная модель с CSA-модулем, то есть Cross-Scale Spatial Attention. Она лучше объединяет признаки encoder и decoder и помогает модели фокусироваться на важных областях изображения. В проекте SA-UNetv2 рассматривалась как специализированная альтернатива U-Net ResNet34 для сегментации сосудов сетчатки.

Финальная серия экспериментов проводилась в одинаковых условиях: seed = 42, 60 эпох, одинаковый train/validation split и одинаковая оценка внутри FOV. Всего сравнивались 17 конфигураций model + loss, а критерием выбора был максимальный validation Dice. Лучший результат показала модель SA-UNetv2 + BCE + MCC: Dice = 0.7699, IoU = 0.6258, Precision = 0.7631, Recall = 0.7768, Accuracy = 0.9373. Результат близок к SA-UNetv2 + BCE + Dice, где Dice = 0.7689, но именно BCE + MCC дала

наибольшее значение основной метрики. По сравнению с baseline U-Net ResNet34 + BCE Dice вырос с 0.6978 до 0.7699, то есть улучшение составило 0.0721.

Важно, что не все содержательные идеи дали максимальный результат. Joint pixel/segment-level loss для SA-UNetv2 дал Dice = 0.7475, что ниже, чем у BCE + MCC и BCE + Dice. При этом у него была высокая Precision = 0.8264, но более низкий Recall = 0.6824. Это означает, что модель предсказывала сосуды осторожно и редко ошибалась в положительных предсказаниях, но пропускала часть сосудистых пикселей. Похожий компромисс был у Weighted BCE: Recall = 0.8982, но Precision = 0.5978, то есть модель находила больше сосудов, но дорисовывала лишние области. Поэтому итоговая модель выбиралась не только по способности находить сосуды, но и по балансу ошибок.

Главный итог работы состоит в том, что был построен полный экспериментальный пайплайн для задачи сегментации при дисбалансе классов: от EDA и анализа литературы до реализации baseline, специализированных функций потерь, segment-level подхода, SA-UNetv2 и финального сравнения. Лучший результат был получен за счет сочетания предобработки, attention-архитектуры и функции потерь BCE + MCC.

При этом проект имеет ограничения: датасет маленький, validation split включает только 4 изображения, а тонкие сосуды остаются сложными для распознавания. Поэтому результаты стоит интерпретировать как честное экспериментальное сравнение в рамках выбранных условий, а не как абсолютный максимум качества на DRIVE.