



ПРЕЗИДЕНТСКАЯ
АКАДЕМИЯ

СЕГМЕНТАЦИЯ ПРИ ДИСБАЛАНСЕ КЛАССОВ

Глуходед Мария, Кочукова Тамара, Маликова Ульяна

Москва, 2026

2025

РАНХиГС

ПРОБЛЕМА

Сегментация при сильном дисбалансе классов

— датасет: DRIVE, сосуды сетчатки

- Фон доминирует по числу пикселей
- Класс сосудов занимает малую область
- Тонкие сосуды теряются чаще всего
- Accuracy может быть высокой даже при плохой сегментации сосудов
- Baseline-модель смещается в сторону фона и крупных сосудов

ЦЕЛЬ ПРОЕКТА

Повысить качество сегментации малого класса

— через специальные методы обучения


- Взять DRIVE как медицинский датасет с дисбалансом
- Обучить baseline U-Net
- Добавить методы борьбы с imbalance
- Проверить SA-UNetv2 и joint pixel/segment-level loss
- Сравнить Dice, IoU, Recall, Precision
- Выбрать модель, которая лучше сохраняет тонкую сосудистую структуру

DRIVE выбран как медицинский кейс сегментации при сильном дисбалансе классов

ДАТАСЕТ

DRIVE: Digital Retinal Images for Vessel Extraction


- 40 цветных изображений глазного дна
- В обучающей части: **20 изображений + 20 binary masks**
- Размер изображения: **584 × 565 px**
- Задача: классифицировать каждый пиксель как **vessel / background**
- Используется **FOV mask**, чтобы не учитывать чёрную область вне сетчатки
- Для экспериментов train/val split: **16 / 4 изображения**



EDA

Анализ подтвердил сильный дисбаланс классов

- По всему изображению сосуды занимают около **8.6%** пикселей
- Внутри FOV сосуды занимают около **12.5%**, фон — **87.5%**
- Соотношение background / foreground внутри FOV: примерно **7 : 1**
- Доля сосудов различается по изображениям: **8.7%–16.8%**
- **Ассурасу может быть завышена из-за доминирования фона**
- Основные метрики: **Dice, IoU, Precision, Recall**



Baseline model

U-Net + ResNet34 encoder

Input: RGB image

Output: vessel mask

Loss: BCEWithLogitsLoss

Metrics: inside FOV mask

Val Dice: **0.6978**

Val IoU: **0.5358**




Схема архитектуры baseline


Original resized



green_clahe



Ground truth






Fig. 2. The Architecture of SA-UNetv2.

Cross-scale Spatial Attention объединяет encoder и decoder features и лучше восстанавливает тонкие сосуды.

Каналы: **16–32–48–64**

Всего **0.26M parameters**, модель легче SA-UNet почти в 2 раза.

Weighted BCE + MCC loss

BCE отвечает за pixel-wise accuracy, MCC — за баланс foreground/background.

Model	F1	Jaccard	Params
SA-UNet	82.44	70.15	0.54M
SA-UNetv2	82.82	70.69	0.26M

Loss functions: сравнение методов обучения при дисбалансе классов

Все loss считались внутри FOV mask после препроцессинга: green channel + CLAHE

BCE — Binary Cross-Entropy

штрафует каждый пиксель отдельно

$$- [y \log(\hat{p}) + (1 - y) \log(1 - \hat{p})]$$

- + стабильный градиент, легко обучается
- плохо работает при дисбалансе классов: фон доминирует над сосудами

Weighted BCE

увеличивает штраф за ошибки на классе сосудов

$$- [w_1 y \log(\hat{p}) + w_0 (1 - y) \log(1 - \hat{p})]$$

- + компенсирует перекося background / vessel
- веса нужно подбирать аккуратно

BCE + Dice

попиксельная ошибка + overlap масок

$$L = 0.5 \cdot BCE + 0.5 \cdot DiceLoss$$

- + стабильный градиент от BCE
- + Dice учитывает качество сегментации сосудов
- BCE чувствителен к доминированию фона

Focal Loss

снижает вклад легких пикселей и усиливает сложные

$$-\alpha(1 - \hat{p}_t)^\gamma \log(\hat{p}_t)$$

- + модель меньше "учится на легком фоне"
- + полезна при сильном дисбалансе
- чувствительна к параметрам α и γ

Tversky Loss

позволяет отдельно управлять штрафом за FP и FN

$$1 - \frac{TP}{TP + \alpha FP + \beta FN}$$

- + можно сильнее штрафовать пропущенные сосуды
- + полезно для повышения recall
- при неверных параметрах может ухудшить precision

BCE + MCC

учитывает не только ошибку пикселя, но и баланс TP, TN, FP, FN

$$L_{MCC} = 1 - MCC$$

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

- + устойчивее при дисбалансе классов
- + учитывает все типы ошибок

Loss функция: joint pixel-wise + segment-level

Loss учитывает не только отдельные пиксели, но и структуру сосудов

$$L_{\text{joint}} = \alpha \cdot L_{\text{pixel}} + (1 - \alpha) \cdot L_{\text{segment}}$$

Pixel-wise loss

Сравнивает предсказание и ground truth на уровне каждого пикселя.

Отвечает за базовое разделение: vessel / background

- при дисбалансе сильнее ориентируется на фон и толстые сосуды.

Segment-level loss

Оценивает ошибку не только по пикселям, но и по сосудистым сегментам.

Использует веса, зависящие от несоответствия толщины сегмента.

Сильнее штрафует ошибки на тонких сосудах.


Зачем это нужно:

Тонкие сосуды занимают мало пикселей и слабо влияют на обычную pixel-wise loss


Обычная loss сильнее ориентируется на толстые сосуды и фон

Segment-level часть увеличивает штраф за ошибки толщины тонких сосудов


Input image




Ground truth mask




FOV mask




Skeleton from GT mask




Search segment id map




Segment skeleton length map



Target vessel thickness tv_gt

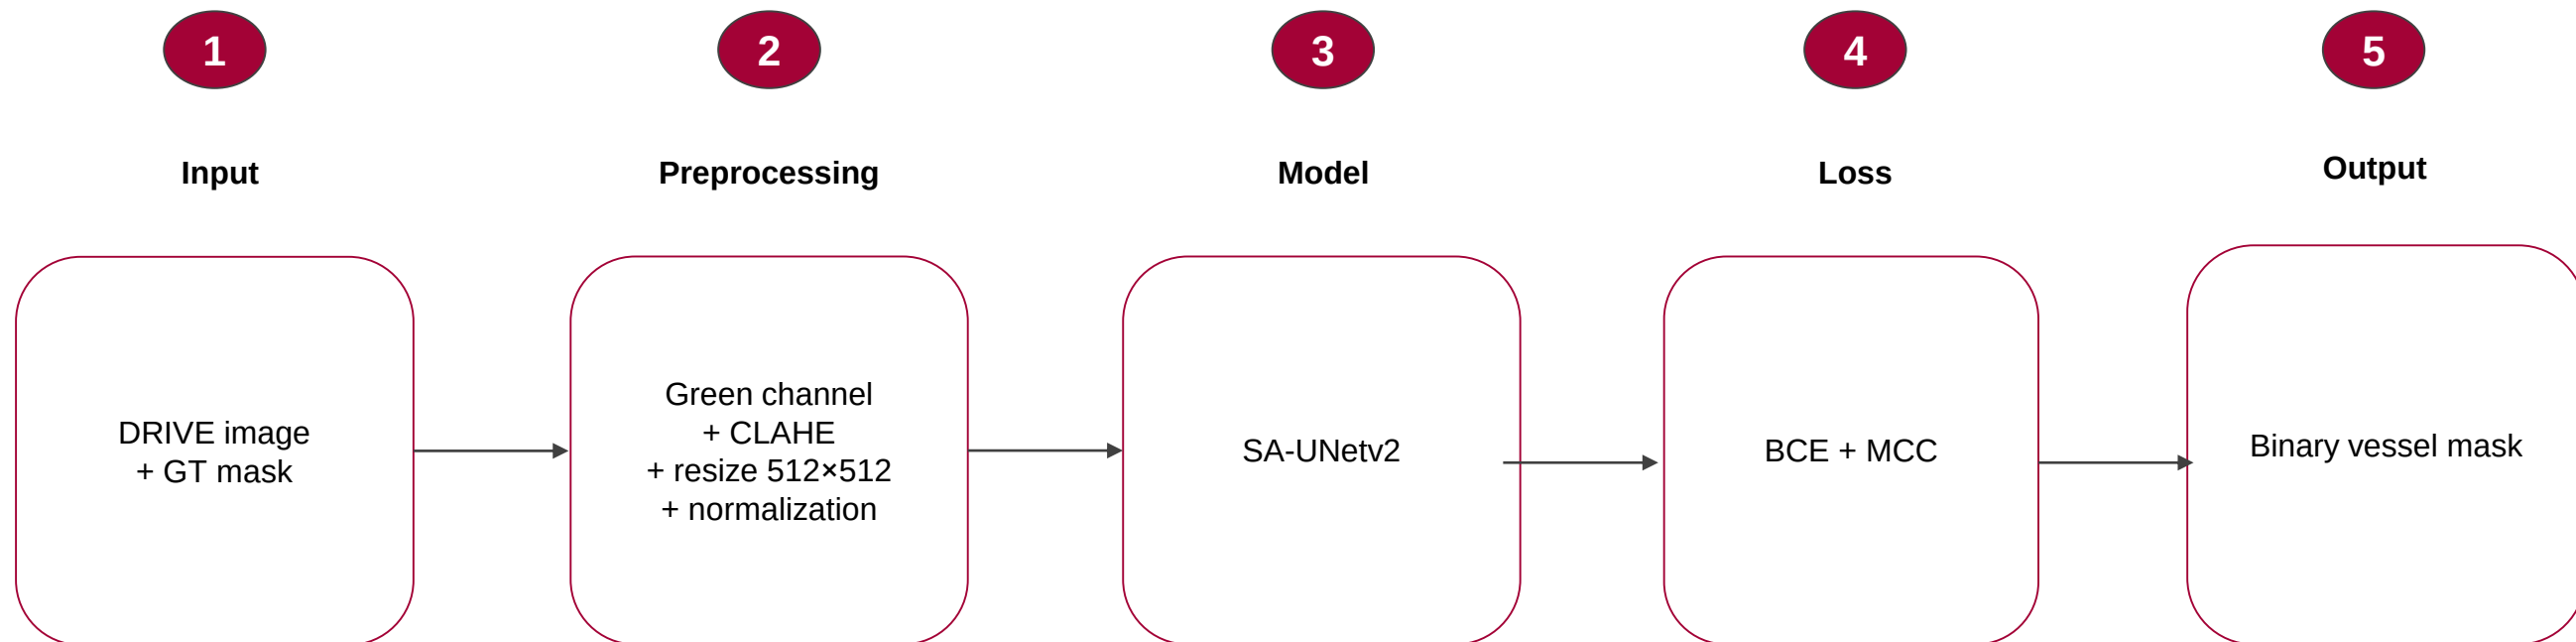


Overlay: red=segment search, green=vessels





	architecture	loss	best_epoch	best_val_loss	best_val_dice	best_val_iou	best_val_precision	best_val_recall	best_val_accuracy
0	SA-UNetv2	BCE + MCC	59	0.2966	0.7699	0.6258	0.7631	0.7768	0.9373
1	SA-UNetv2	BCE + Dice	58	0.2720	0.7689	0.6245	0.7656	0.7721	0.9373
2	SA-UNetv2	Focal Loss	59	0.0196	0.7594	0.6121	0.6991	0.8310	0.9289
3	SA-UNetv2	BCE	57	0.1916	0.7573	0.6094	0.7852	0.7313	0.9367
4	SA-UNetv2	Focal Tversky Loss	58	0.3797	0.7532	0.6042	0.6616	0.8744	0.9227
5	SA-UNetv2	Tversky Loss	52	0.2945	0.7506	0.6008	0.6692	0.8545	0.9234
6	SA-UNetv2	Joint pixel-wise + segment-level	53	0.2372	0.7475	0.5968	0.8264	0.6824	0.9378
7	U-Net ResNet34	BCE + Dice	60	0.3749	0.7364	0.5828	0.6976	0.7798	0.9247
8	U-Net ResNet34	BCE + MCC	60	0.4094	0.7342	0.5800	0.6787	0.7995	0.9219
9	U-Net ResNet34	BCE	57	0.2785	0.7201	0.5627	0.7361	0.7049	0.9261
10	SA-UNetv2	Weighted BCE	52	0.4617	0.7179	0.5599	0.5978	0.8982	0.9047
11	U-Net ResNet34	Focal Loss	60	0.0245	0.7156	0.5571	0.6663	0.7727	0.9171
12	U-Net ResNet34	Joint pixel-wise + segment-level	60	0.2863	0.7150	0.5565	0.7416	0.6903	0.9258
13	U-Net ResNet34	Weighted BCE	59	0.5627	0.7150	0.5564	0.6251	0.8350	0.9102
14	U-Net ResNet34	Focal Tversky Loss	60	0.4684	0.7124	0.5533	0.6156	0.8453	0.9079
15	U-Net ResNet34	Tversky Loss	60	0.3689	0.7091	0.5493	0.6155	0.8363	0.9074
16	U-Net ResNet34	BCE	60	0.2860	0.6978	0.5358	0.7234	0.6739	0.9212

**Best experiment:**

SA-UNetv2 + BCE + MCC

Dice = 0.7699

IoU = 0.6258

Precision = 0.7631


Recall = 0.7768

Accuracy = 0.9373

Критерий выбора: максимальный validation Dice

$$\text{Dice} = 2 \cdot \text{TP} / (2 \cdot \text{TP} + \text{FP} + \text{FN})$$

Дополнительно контролировали IoU и баланс Precision / Recall, чтобы модель не только находила сосуды, но и не дорисовывала лишний фон.





ПРЕЗИДЕНТСКАЯ
АКАДЕМИЯ

СПАСИБО ЗА ВНИМАНИЕ!

Москва

2025

РАНХиГС